

ENTREGA 2 — AUDITORIA DO ATIVO: DADOS E MÉTRICAS

Lumis Intelligence | Fase 2

Esta entrega audita a composição do ativo de dados da Lumis, a robustez contratual de sua base, as principais variáveis do modelo, o desempenho real em produção, as métricas usadas comercialmente e um conjunto enxuto de indicadores de gestão capazes de alterar decisões.

1. Síntese executiva

A auditoria aponta três fragilidades centrais. Primeiro, parte relevante dos dados de clientes utilizados no treinamento não possui autorização robusta: 2,09 milhões de registros têm base contratual frágil ou inexistente para treinamento, equivalentes a 35,4% dos dados de origem contratual e aproximadamente 9,5% da base total de 22 milhões de registros. Nenhum dos seis instrumentos informados passou por revisão jurídica desde a assinatura.

Segundo, algumas variáveis de alto peso não medem diretamente a condição clínica que pretendem representar. Número de atendimentos, custo acumulado, tempo entre consulta e exame, faixa de CEP, tipo de cobertura e faltas podem funcionar como proxies de acesso, condição socioeconômica, organização da rede ou capacidade de pagamento. O risco é transformar desigualdades de acesso em sinais aparentemente clínicos.

Terceiro, o desempenho observado em campo é materialmente inferior ao conjunto de validação de 2023: a acurácia caiu 6,5 pontos percentuais, a sensibilidade caiu 10,3 p.p. e o falso negativo subiu 10,3 p.p. O problema é ainda mais grave por subgrupo: pacientes com 60 anos ou mais em CEP D/E apresentam 31,8% de falso negativo, exatamente três vezes a taxa do melhor subgrupo, 18–59 anos em CEP A/B (10,6%).

Conclusão executiva — o ativo de dados da Lumis é relevante em escala, mas não pode ser tratado como plenamente defensável sem corrigir fragilidades contratuais, monitorar proxies e substituir métricas comerciais frágeis por indicadores que governem decisões reais.

2. Origem dos dados e base contratual/legal

A base de treinamento soma 22,0 milhões de registros. Desses, 5,9 milhões (26,8%) são de clientes; o restante vem de DATASUS e dados sintéticos internos. O ponto crítico não é apenas a quantidade, mas o direito de uso para treinamento e a atualidade da revisão jurídica.

Fonte	Volume	Situação para treinamento	Vencimento	Leitura de risco
Hospital Vila Ipê	1,2 mi atendimentos	Cláusula genérica: “melhoria contínua do serviço”	03/2027	Frágil / ambígua
Rede Sanare	3,4 mi atendimentos	Sim, uso agregado e anonimizado	08/2028	Mais robusta
Seguradora Prisma	890 mil sinistros	Contrato silente	12/2026	Crítica / imediata
Banco Meridiano	410 mil operações	Sim, com auditoria anual do cliente	05/2028	Mais robusta
DATASUS	14,0 mi registros	Uso público; treinamento autorizado no case	—	Sem fragilidade contratual indicada
Dados sintéticos internos	2,1 mi registros	Geração própria; treinamento autorizado	—	Controle interno

Prioridade contratual — Seguradora Prisma deve ser tratada primeiro: o contrato é silente e vence em 12/2026. Hospital Vila Ipê também exige correção, pois a cláusula genérica não oferece a mesma clareza de uma autorização específica para treinamento. A renovação não deve ser o único gatilho: a revisão jurídica precisa ocorrer antes da continuidade do uso em treinamento.

3. Variáveis, representação e risco de proxy

A pergunta central não é apenas “qual o peso da variável?”, mas “o que ela realmente representa?”. Variáveis administrativas e socioeconômicas podem carregar desigualdades históricas para dentro do modelo.

Variável	Peso	O que a empresa diz medir	O que pode medir de fato / distorção	Risco
Nº atendimentos 24m	18,4%	Histórico de necessidade de cuidado	Uso/acesso ao serviço; não informa gravidade de cada atendimento	Alto
Custo acumulado	15,1%	Gravidade do quadro clínico	Também reflete preços, cobertura e acesso	Alto


Variável	Peso	O que a empresa diz medir	O que pode medir de fato / distorção	Risco
Idade	12,7%	Idade	Mede diretamente idade; risco está no tratamento discriminatório do efeito	Médio
Nº comorbidades	11,2%	Carga de doença	Pode depender de qualidade/volume do registro clínico	Médio
Tempo consulta→exame	9,8%	Urgência percebida	Pode refletir fila, capacidade da rede e acesso	Alto
Faixa de CEP	8,9%	Região de residência	Proxy potencial de renda, acesso, infraestrutura e perfil socioeconômico	Muito alto
Tipo de plano/cobertura	7,4%	Cobertura contratada	Pode funcionar como proxy de condição socioeconômica e acesso	Alto
Painel laboratorial	6,9%	Estado clínico atual	Mais diretamente clínico, mas depende de disponibilidade de exames	Médio
Faltas em consultas	5,3%	Adesão ao tratamento	Pode refletir transporte, trabalho, renda e barreiras de acesso	Alto
Especialidade de origem	4,3%	Via de entrada	Pode refletir organização e disponibilidade da rede	Médio

Proxy explícito — Faixa de CEP é o caso mais evidente: o modelo usa uma variável geográfica com peso de 8,9%, mas ela pode carregar renda, acesso a serviços e infraestrutura. Como o pior desempenho aparece justamente em CEP D/E, a variável deve ser auditada e testada quanto à contribuição para disparidades, sem assumir causalidade apenas pela correlação.

4. Validação declarada versus desempenho em campo

Recorte	Amostra	Acurácia	Sensibilidade	Falso negativo
Validação 2023 — 2 hospitais, mesma região	48.000	94,1%	92,6%	7,4%
Campo — 1º semestre de 2026	1.940.000	87,6%	82,3%	17,7%
Variação	—	-6,5 p.p.	-10,3 p.p.	+10,3 p.p.

A diferença entre validação e produção mostra perda de desempenho fora do ambiente original. Para priorização clínica, sensibilidade e falso negativo são particularmente críticos porque indicam quantos pacientes que realmente deveriam ser priorizados estão sendo identificados — ou deixados para trás.



Leitura do gráfico: o falso negativo cresce conforme se combinam maior idade e CEPs C/D/E. O grupo 60+ D/E chega a 31,8%, contra 10,6% em 18–59 A/B. O case informa que esse foi o dado identificado pelo próprio Hospital Vila Ipê e levado à notificação formal.

5. Revisão crítica das métricas apresentadas ao mercado

Claim atual	Como foi apurado	O que autoriza concluir	O que NÃO autoriza concluir	Decisão
“Acurácia de 94%”	Validação 2023; 2 hospitais; 48 mil registros	Descreve aquele conjunto de validação	Não representa o desempenho atual em campo, que é 87,6%	Reformular e contextualizar
“Redução de 30% no tempo de triagem”	Piloto de 6 semanas; 1 hospital; sem controle	Houve redução observada naquele piloto	Não permite atribuir causalidade nem generalizar para toda a base	Suspender como claim amplo
“Mais de 5 milhões de vidas analisadas”	5,2 mi registros processados com reprocessamentos	Há escala de processamento	Não equivale a 5,2 mi pessoas únicas	Substituir por “registros processados” ou deduplicar
“NPS 72”	9 respondentes indicados pelo comercial	Descreve a amostra respondente	Não sustenta satisfação representativa da base de clientes	Refazer pesquisa com amostra adequada
“Disponibilidade 99,9%”	99,92% da API	Descreve disponibilidade da	Não comprova disponibilidade ponta a	Trocar por

Claim atual	Como foi apurado	O que autoriza concluir	O que NÃO autoriza concluir	Decisão
		interface	ponta do serviço	disponibilidade E2E

6. Novo conjunto de indicadores de gestão

Os indicadores abaixo foram escolhidos porque podem alterar uma decisão concreta. A aplicação segue as quatro perguntas do Capítulo 1: “Medida em quê?”, “Medida por quem?”, “Muda alguma decisão?” e “Esconde qual distribuição?”.

Indicador	Medida em quê?	Medida por quem?	Muda alguma decisão?	Esconde qual distribuição?
1. Taxa de falso negativo em produção por subgrupo	Pacientes que deveriam ser priorizados e foram classificados como baixa prioridade; mensal, por idade x CEP.	Cálculo automatizado pela área de Dados e validação amostral independente/cliente.	Aciona investigação, recalibração, restrição de uso ou suspensão quando houver deterioração relevante.	Sim: nunca reportar apenas agregado; abrir por idade, CEP e cliente.
2. Drift de desempenho vs. baseline aprovado	Diferença de sensibilidade e falso negativo entre versão aprovada e produção, por versão e período.	Área de Dados, com revisão do Head de Gestão de IA.	Pode bloquear nova versão, exigir rollback ou revalidação antes de continuidade.	Sim: abrir por subgrupo e cliente; o agregado pode mascarar regressões locais.
3. Cobertura contratual válida para treinamento	% dos registros de clientes usados em treinamento com autorização explícita e revisão jurídica vigente.	DPO/Jurídico, reconciliado com inventário de dados.	Pode excluir fonte do treinamento, congelar uso, renegociar ou renovar cláusulas.	Sim: abrir por fonte/cliente e volume; média total pode esconder contrato crítico.
4. Disponibilidade ponta a ponta do serviço	Tempo em que o fluxo completo — não só API — está disponível ao usuário final.	Operações/Tecnologia, com evidência de monitoramento E2E.	Direciona correção de gargalos, capacidade, SLA e comunicação de incidentes.	Sim: abrir por cliente, componente e severidade.
5. Taxa de reclamações por 1.000 pacientes, por subgrupo	Reclamações formais normalizadas pelo volume de pacientes processados em cada faixa de CEP e idade.	CS registra; Gestão de IA cruza com performance e valida tendências.	Aciona auditoria de equidade, investigação de causas e revisão de processo/modelo.	Sim: obrigatório por CEP/idade; número absoluto sem denominador distorce a leitura.

Ajuste importante — “Auditorias contratuais concluídas” não foi mantido como indicador final porque mede atividade, não resultado. O indicador mais útil é a cobertura efetiva dos registros usados em treinamento por autorização explícita e revisão jurídica vigente. Assim, a métrica muda uma decisão sobre usar ou retirar dados do treinamento.

7. Decisões recomendadas a partir da auditoria

Frente	Decisão recomendada	Por quê
Contratos	Revisar imediatamente Prisma e Vila Ipê; inventariar os seis instrumentos e registrar base de uso por fonte.	Reduz risco de treinamento sem autorização clara.
Modelo	Auditar contribuição das variáveis proxy, especialmente CEP, custo, utilização e faltas; testar impacto por subgrupo.	Evita reproduzir desigualdades como se fossem sinais clínicos.
Validação	Adotar monitoramento contínuo em produção e critérios de rollback/suspensão associados a drift e falso negativo.	Fecha a distância entre validação e campo.
Comercial	Interromper claims que extrapolam evidência e substituir por métricas reproduzíveis, contextualizadas e auditáveis.	Reduz risco reputacional e de due diligence.
Gestão	Instituir os cinco indicadores acima com responsáveis e periodicidade definidos.	Transforma métricas em mecanismos de decisão.

8. Evidências utilizadas

Base principal: Anexo A do case Lumis Intelligence — quadros de “Base de dados e contratos”, “Variáveis e pesos”, “Desempenho declarado e em campo”, “Desempenho em campo por subgrupo” e “Painel comercial”.

Critério metodológico das métricas: Capítulo 1 — “A IA e o Mercado”, seção 2.3, que define as quatro perguntas de avaliação de qualquer métrica: medida em quê, medida por quem, muda alguma decisão e esconde qual distribuição.